



復旦大學
FUDAN UNIVERSITY

SelfCheckGPT: 复现与增强零资源黑盒幻觉检测

时间：2025-11-26

博学而笃志 切问而近思

目录

CONTENTS

01

选题介绍

对选题背景和课题目标进行简要介绍

02

当前进度

对复现实验的设计和结果进行概述

03

未来方向

对下一阶段要完成的任务进行梳理

01

选题介绍

选题背景:

核心问题: 大语言模型幻觉

定义:

在自然语言处理领域, 幻觉通常被定义为生成内容无意义或与提供的源内容不一致的现象。

分类:

事实幻觉(Factuality Hallucination): 事实矛盾, 事实捏造。

忠实性幻觉(Faithfulness Hallucination): 指令不一致, 上下文不一致, 逻辑不一致。

(Huang et al., 2023)

选题背景:

大语言模型幻觉以事实层面的幻觉为主：模型在不确定时有时会选择猜测，生成看似合理但不正确的陈述，而非承认自身的不确定性。


大语言模型幻觉的产生，

一方面有预训练时统计上的必然性，标准的交叉熵训练目标天然会导致错误（生成错误的错误率受限于一个等价的二元分类任务的性能）；

另一方面是评估中有缺陷的激励机制导致幻觉持续存在（主流的二元评分评估基准系统性地惩罚表达不确定性，并奖励猜测行为，导致模型被优化得过度自信）。(Kalai et al., 2025)

因此，有必要找到高效可靠的方法来检测大语言模型幻觉。

大语言模型幻觉检测方法:



选题背景:

以往方法的局限性:

- 灰盒方法依赖内部信息: 需要访问LLM的内部输出分布, 在黑盒系统(如ChatGPT)中不可用。
- 外部数据库依赖: 复杂、受限于数据库的覆盖范围、推理成本高。
- 任务泛化能力不足: 多集中于特定任务(如摘要、对话), 缺乏对通用LLM响应的幻觉检测方法。

Manakul, Potsawee, Adian Liusie, and Mark Gales. "Selfcheckgpt: Zero-resource black-box hallucination detection for generative large language models." Proceedings of the 2023 conference on empirical methods in natural language processing. 2023.

SelfCheckGPT:

- 零资源与黑盒兼容: 无需外部数据库或模型内部信息, 仅通过采样和比较响应即可工作。
- 通用性: 首次针对通用LLM响应(非特定任务)进行幻觉检测。
- 多维度一致性评估: 提出五种不同的一致性度量方法, 覆盖从表面相似度到语义推理的不同层面。

核心思路:

基于“事实性内容在多次采样中保持一致”的前提假设，
通过从同一查询中采样多个LLM响应，比较它们之间的一致性。
如果响应一致，则认为内容事实性高；如果不一致，则可能存在幻觉。

采用五种一致性检测方法：

BERTScore（语义相似度）

NLI（自然语言推理）

MQAG（问答一致性）

n-gram（语言模型概率）

Prompt（大语言模型自评估）

使用GPT-3生成WikiBio数据集的维基百科风格文章，并手动标注句子级别的事实性。

评估五种检测方法的句子级幻觉检测和段落级事实检测能力。

(Manakul et al., 2023)

课题目标:

第一阶段: 复现SelfCheckGPT实验, 实现零资源黑盒幻觉检测, 测试其性能。

第二阶段: 进行增强实验并扩展研究:

- 集成方法研究

- 跨语言评估研究

- 效率分析

02 当前进度

一、实验目标

对齐SelfCheckGPT原论文的5种幻觉检测方法（NLI/BERTScore/Ngram/MQAG/Prompt），验证SelfCheckGPT系列方法对 GPT-3 生成文本的幻觉识别能力。

采用原论文评估体系，将评估结果与原论文实验进行对比，确保复现的准确性和可比性。

二、数据集信息

采用原论文使用的WikiBio GPT-3 Hallucination Dataset

1. 数据规模:

238个GPT-3生成的传记（传记类文本事实性强、幻觉易量化和评估）

1908个句子级标注（0.0/0.5/1.0）

单篇平均句子数：8 个

每个实例配置20个采样段落（同一Prompt生成）

2. 标注体系（句子级）：

三分类标注：

0.0: Factual（完全事实）

0.5: Minor Hallucination（轻微幻觉）

1.0: Major Hallucination（严重幻觉）

3. 数据预处理：

句子分割：spaCy en_core_web_sm 模型（与SelfCheckBERTScore代码一致）

无效过滤：剔除长度<3字符的句子、长度<50字符的采样段落

三、针对五种方法的实验设置

- 输入格式：待检测句子列表 + 原始传记上下文+ 20 个采样段落（自一致性证据）。
- 量化待检测句子与采样段落的一致性，一致性越低，句子幻觉概率越高。
- 输出格式：句子级分数（0~1，分数越高，幻觉概率越高）。

1. SelfCheckNLI

基于 NLI（自然语言推理）判断待检测句子与采样段落的矛盾程度：矛盾概率 = 幻觉分数

模型选型：DeBERTa-v3-Large

2. SelfCheckBERTScore

计算待检测句子与采样段落中最佳匹配句的 BERTScore-F1 语义相似度：1 - 相似度 = 幻觉分数

模型选型：RoBERTa-Large

3. SelfCheckNgram

基于原始传记 + 20 个采样段落构建 Unigram 语言模型，计算待检测句子的负对数概率，归一化后为幻觉分数

模型选型：Unigram 模型

4. SelfCheckMQAG

通过问答的方式来检测一致性：

- (1) 基于待检测句子生成5个问答对，每个问题都配有3个干扰项（共4个选项）；
 - (2) 用原始传记和20个采样段落分别回答问题，得到答案概率分布；
 - (3) 计算概率分布差异（软计数贝叶斯方法）来判断幻觉程度，差异越大则幻觉分数越高
- 模型选型：

- G1（问题生成）：MQAGConfig.generation1_squad（默认配置）
- G2（干扰项生成）：MQAGConfig.generation2（T5-Large 基础模型）
- A（问答）：Longformer-Large（MQAGConfig.answering，支持长文本）
- U（可回答性判断）：Longformer-Large（MQAGConfig.answerability，过滤无效问题）

5. SelfCheckPrompt

基于大模型的推理能力，直接询问待检测句子是否被采样段落支持：不支持概率 = 幻觉分数
模型选型：Qwen-7B-Chat

Prompt模板（依照原论文格式）：

- Context: {context}
Sentence: {sentence}
Is the sentence supported by the context above?
Answer Yes or No:
- 推理策略: temperature=0.0（确定性生成，无随机波动，确保结果的可重复性）
- 最大新 tokens: 10（仅输出 Yes/No）

回答解析逻辑：

- 提取生成文本的第一个单词
- 前缀匹配: startswith('yes')→0.0, startswith('no')→1.0
- 解析失败（非 Yes/No）→0.5（中性）

四、评估指标

1. 句子级: NonFact/NonFact*/Factual AUC-PR

AUC-PR (Precision-Recall Curve Area)

基于数据集标注不平衡事实（事实句占比偏高），比AUC-ROC更能反映模型真实检测能力。

评估三个不同的任务，从不同角度全面评估模型的幻觉检测能力：

- NonFact AUC-PR

正例：标注 ≥ 0.5 （轻微 + 严重幻觉）；负例：标注 = 0.0（完全事实）

检测所有非事实性句子，衡量区分事实/非事实的能力

- NonFact* AUC-PR

正例：标注 = 1.0（严重幻觉）；负例：标注 ≤ 0.5 （完全事实 + 轻微幻觉）

专门检测严重幻觉，衡量检测严重幻觉的能力

- Factual AUC-PR

正例：标注 = 0.0（完全事实）；负例：标注 ≥ 0.5 （轻微 + 严重幻觉）


识别事实性句子，衡量识别事实的能力（避免事实句误判为幻觉）

四、评估指标

2. 段落级：Pearson相关系数

- 段落级分数：单篇传记所有句子的检测分数取平均值（反映段落整体幻觉程度）；
- 人工标注映射：句子级标注加权平均，聚合为段落级分数；
- 相关性计算：方法输出段落分数与人工幻觉程度的 Pearson 相关系数。
- 验证模型从句子级检测到段落级评估的迁移能力。

五、项目结构



基于部分样本 (文本篇数50/238) 的复现实验结果如下:

SelfCheckBERTScore:

句子级: NonFact AUC-PR 0.8250

段落级: Pearson 0.5658

Spearman 0.4677

样本数 (句子级标注): 423

SelfCheckNLI:

句子级: NonFact AUC-PR 0.9222

段落级: Pearson 0.7163

Spearman 0.7116

样本数 (句子级标注): 423

SelfCheckMQAG:

句子级: NonFact AUC-PR 0.7991

段落级: Pearson 0.5423

Spearman 0.5439

样本数 (句子级标注): 423

SelfCheckNgram:

句子级: NonFact AUC-PR 0.8659

段落级: Pearson: 0.4370

Spearman 0.3868

样本数 (句子级标注): 423

SelfCheckQwenPrompt:

句子级: NonFact AUC-PR 0.8889

段落级: Pearson 0.5352

Spearman 0.5794

样本数 (句子级标注): 423

部分样本（文本篇数50/238）的复现实验结果，与原论文各方法的指标对比如下：

方法	复现结果 (NonFact AUC-PR)	原论文结果 (NonFact AUC-PR)
SelfCheckNLI	0.9222	0.9250
SelfCheckBERTScore	0.8250	0.8196
SelfCheckNgram	0.8659	0.8563
SelfCheckMQAG	0.7991	0.8426
SelfCheckprompt	0.8889	0.9342

从 NonFact AUC-PR 指标来看，所有方法均接近甚至略微超过原论文方法的性能。
所有方法的偏差均在 ± 0.05 以内，低于“显著偏差” 阈值（ ± 0.1 ）。

因此，认为复现的方法基本正确，进一步在全部样本的基础上运行程序，继续实验(耗时较长)。
增加了 NonFact* AUC-PR 和 Factual AUC-PR 两个指标，更加全面地进行评价。

基于全部样本 (238篇文本, 1908个句子级标注) 的复现实验结果如下:

SelfCheckNgram:

NonFact AUC-PR: 0.8517

NonFact* AUC-PR: 0.5939

Factual AUC-PR: 0.1868

样本数: 1908

SelfCheckNLI:

NonFact AUC-PR: 0.9250

NonFact* AUC-PR: 0.5838

Factual AUC-PR: 0.1624

样本数: 1908

SelfCheckPrompt:

NonFact AUC-PR: 0.8837

NonFact* AUC-PR: 0.5003

Factual AUC-PR: 0.1786

样本数: 1908

SelfCheckBERTScore:

NonFact AUC-PR: 0.8120

NonFact* AUC-PR: 0.5746

Factual AUC-PR: 0.2076

样本数: 1908

SelfCheckMQAG:

NonFact AUC-PR: 0.8520

NonFact* AUC-PR: 0.5111

Factual AUC-PR: 0.1862

样本数: 1890

方法	指标	复现结果(AUC-PR)	原论文结果(AUC-PR)	评价
SelfCheckNLI	NonFact	0.9250	0.9250	完全一致
	NonFact*	0.5838	0.4517	显著偏高
	Factual	0.1624	0.6608	严重偏低
SelfCheckBERTScore	NonFact	0.8120	0.8196	非常接近
	NonFact*	0.5746	0.4596	显著偏高
	Factual	0.2076	0.4423	严重偏低
SelfCheckNgram	NonFact	0.8517	0.8563	非常接近
	NonFact*	0.5939	0.4104	显著偏高
	Factual	0.1868	0.5847	严重偏低
SelfCheckMQAG	NonFact	0.8520	0.8426	非常接近
	NonFact*	0.5111	0.4006	显著偏高
	Factual	0.1862	0.4814	严重偏低
SelfCheckPrompt	NonFact	0.8837	0.9342	略微偏低
	NonFact*	0.5003	0.5319	略微偏低
	Factual	0.1786	0.6709	严重偏低

NonFact AUC-PR 与原论文结果很接近，NonFact* AUC-PR 大多与原论文相比偏高。
说明复现方法对于幻觉（所有不准确句子，包括轻微 + 严重幻觉）的检测性能与原论文相近，且对于严重幻觉的检测能力强于原论文。

然而，Factual AUC-PR 远低于原论文结果，在事实性句子识别上存在明显差距，表明我们的方法将大量真实的事实性句子错误地判定为“不实”或“幻觉”，即方法存在严重的“假阳性”问题。

进行检查后发现在Factual任务中，我们需要检测事实性句子，但SelfCheckGPT输出的是幻觉分数，我们没有进行相应的分数转换，直接使用了原始分数计算AUC-PR，导致结果异常偏低。

对处理进行了调整后，我们在部分样本（50篇文本）上测试了调整后的性能，观察各个指标尤其是 Factual AUC-PR 是否得到提升。采用三个句子级指标 (NonFact, NonFact*, Factual AUC-PR)，并增加两个段落级指标 (Pearson, Spearman) 来进行评价。

调整后基于部分样本 (文本篇数50/238)
的复现实验结果如下:

SelfCheckNgram:

句子级: NonFact AUC-PR 0.8659
NonFact* AUC-PR 0.5681
Factual AUC-PR 0.4512
段落级: Pearson 0.4370
Spearman 0.3868
样本数: 423

SelfCheckNLI:

句子级: NonFact AUC-PR 0.9222
NonFact* AUC-PR 0.5884
Factual AUC-PR 0.5888
段落级: Pearson 0.7163
Spearman 0.7116
样本数: 423

SelfCheckPrompt:

句子级: NonFact AUC-PR 0.8889
NonFact* AUC-PR 0.5200
Factual AUC-PR 0.4723
段落级: Pearson 0.5352
Spearman 0.5794
样本数: 423

SelfCheckBERTScore:

句子级: NonFact AUC-PR 0.8250
NonFact* AUC-PR 0.5869
Factual AUC-PR 0.3543
段落级: Pearson 0.5658
Spearman 0.4677
样本数: 423

SelfCheckMQAG:

句子级: NonFact AUC-PR 0.7991
NonFact* AUC-PR 0.5194
Factual AUC-PR 0.3287
段落级: Pearson 0.5423
Spearman 0.5439
样本数: 423



方法	指标	复现结果(AUC-PR)	原论文结果(AUC-PR)	评价
SelfCheckNLI	NonFact	0.9222	0.9250	接近
	NonFact*	0.5884	0.4517	偏高
	Factual	0.5888	0.6608	偏低
SelfCheckBERTScore	NonFact	0.8250	0.8196	接近
	NonFact*	0.5869	0.4596	偏高
	Factual	0.3543	0.4423	偏低
SelfCheckNgram	NonFact	0.8659	0.8563	接近
	NonFact*	0.5681	0.4104	偏高
	Factual	0.4512	0.5847	偏低
SelfCheckMQAG	NonFact	0.7991	0.8426	偏低
	NonFact*	0.5194	0.4006	偏高
	Factual	0.3287	0.4814	偏低
SelfCheckPrompt	NonFact	0.8889	0.9342	接近
	NonFact*	0.5200	0.5319	接近
	Factual	0.4723	0.6709	偏低

- 在部分样本中，与调整之前相比，Factual AUC-PR得到较大的提升，但与原论文结果相比依然偏低，对事实性句子的识别能力不足。
- 句子级指标中 NonFact AUC-PR 与原论文结果相近，NonFact* AUC-PR 普遍高于原论文结果，说明复现方法检测幻觉和识别严重幻觉的性能较为优秀。
- 段落级指标中各方法的 Pearson 和 Spearman 都低于原论文，
 - 其中NLI的两项指标与原论文最接近 (Pearson 0.7163 / 0.7414 , Spearman 0.7116/0.7378)
 - 其次是BERTScore (Pearson 0.5658 / 0.5818 , Spearman 0.4677 / 0.5590)。
- 各方法 NonFact AUC-PR 指标在原论文中的排序：
 - Prompt > NLI > Ngram > MQAG > BERTScore
 - 复现排序为： NLI > Prompt > Ngram > BERTScore > MQAG
 - 复现的排序中 NLI > Prompt可能是Prompt方法中使用的LLM不同 (GPT-3 / Qwen) 造成的，BERTScore > MQAG 可能是样本较少导致的 (全量运行时排序与之相反) 。
- 五种方法耗时： Ngram < NLI < Prompt << BERTScore << MQAG。
- 综合句子级、段落级指标以及消耗时间的长短，性能最优秀、复现效果最好的是SelfCheckNLI，也符合原论文的结论。

03 未来方向

右侧是原论文中的表格，将SelfCheckGPT与其他幻觉检测方法的各指标进行对比。

目前的复现结果已经达到一个可以接受的范围内，优于表格中列举的一些其他检测方法。但复现的五种方法的Factual AUC-PR 指标仍低于原论文结果，段落级指标Pearson 和 Spearman 也都较低，需要进一步的优化。

前面调整后的程序只在部分样本（文本篇数50/238）的基础上运行过，还未进行完整的实验。在进一步优化之后需要基于全部样本再次进行实验。

Method	Sentence-level (AUC-PR)			Passage-level (Corr.)	
	NonFact	NonFact*	Factual	Pearson	Spearman
Random	72.96	29.72	27.04	-	-
GPT-3 (text-davinci-003)'s probabilities (<i>LLM, grey-box</i>)					
Avg($-\log p$)	83.21	38.89	53.97	57.04	53.93
Avg($\mathcal{H}$) [†]	80.73	37.09	52.07	55.52	50.87
Max($-\log p$)	87.51	35.88	50.46	57.83	55.69
Max($\mathcal{H}$) [†]	85.75	32.43	50.27	52.48	49.55
LLaMA-30B's probabilities (<i>Proxy LLM, black-box</i>)					
Avg($-\log p$)	75.43	30.32	41.29	21.72	20.20
Avg($\mathcal{H}$)	80.80	39.01	42.97	33.80	39.49
Max($-\log p$)	74.01	27.14	31.08	-22.83	-22.71
Max($\mathcal{H}$)	80.92	37.32	37.90	35.57	38.94
SelfCheckGPT (<i>black-box</i>)					
w/ BERTScore	81.96	45.96	44.23	58.18	55.90
w/ QA	84.26	40.06	48.14	61.07	59.29
w/ Unigram (max)	85.63	41.04	58.47	64.71	64.91
w/ NLI	92.50	45.17	66.08	74.14	73.78
w/ Prompt	93.42	53.19	67.09	78.32	78.30

原论文贡献:

第一个考虑通用大语言模型响应幻觉检测任务
提出了 SelfCheckGPT 零资源方法, 适用于任何黑盒LLM, 无需外部资源
在句子和段落级别优于一系列考虑的灰盒和黑盒基线检测方法
发布了带有句子级事实性标签的 GPT-3 幻觉检测标注数据集

局限性:

数据集中, 仅包含个人主题
仅验证英文, 未验证跨语言 (如中文) 适用性
计算成本高、计算效率低
句子级评估可能不够细粒度

- 集成方法：
 - 将表现最好的两种方法通过加权平均组合，验证是否能提升性能。
- 跨语言评估：
 - 使用中文模型，在中文数据集上运行实验方法，并评估性能。
 - 数据准备：考虑到操作可行性，计划将原数据集文本翻译成中文，构建小规模数据集（尽管机器翻译可能引入错误）
 - 目前Prompt方法中采用Qwen-7B-Chat模型，支持中文Prompt方法
 - 另外考虑使用NLI/BERT方法（在英文中表现最好）进行实验
 - 评估：同论文一致，计算句子级别的AUC-PR和段落级别的相关性系数
 - 比较：中文模型与英文模型在中文数据上的表现，以及英文模型在英文数据上的表现。
- 效率分析：
 - 从20个段落中随机抽取5个，重复实验多次取平均，比较与使用20个段落的结果。
 - 原论文仅在Prompt方法中体现测试了4个段落的性能比较。
 - 尝试可行的优化，尝试提升计算效率。

- Manakul, Potsawee, Adian Liusie, and Mark Gales. "Selfcheckgpt: Zero-resource black-box hallucination detection for generative large language models." Proceedings of the 2023 conference on empirical methods in natural language processing. 2023.
- Huang, Lei, et al. "A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions." ACM Transactions on Information Systems 43.2 (2025): 1-55.
- OpenAI. (2025). Why language models hallucinate. arXiv:2509.04664
- 刘泽垣, 王鹏江, 宋晓斌, 张欣, 江奔奔. 大语言模型的幻觉问题研究综述. 软件学报, 2025, 36(3): 1152 – 1185. [http:// www.jos.org.cn/1000-9825/7242.htm](http://www.jos.org.cn/1000-9825/7242.htm)
- Yehuda, Yakir, et al. "InterrogateLLM: Zero-resource hallucination detection in LLM-generated answers." arXiv preprint arXiv:2403.02889 (2024).